# **YAI Final Project**

자연어 프로젝트팀 김우영 김민정 김현식 동용훈 이종우

### Overview

### "신기술 예측을 위한 키워드 분석 및 문장 생성에 관한 연구"





# **Data Preprocessing**

### Keyword

Transformer

Segmentation

**GAN** 

**Object Detection** 

Encoder

Decoder




연도별로 200개의 논문 abstract를 추출



# **Dynamic Topic Models**

Dynamic topic models are generative models that can be used to analyze the evolution of (unobserved) topics of a collection of documents over time.

- 시간적으로 문서집합 내에서 관측되지 않은 주제 (topic)들의 변화를 분석하기 위해 사용되는 생성 모델
- DTM은 크게 LSA 기반 모델과 LDA 기반 모델이 있음
- 본 프로젝트에서는 LDA (Latent Dirichlet Allocation) 기반 DTM을 사용
  - LDA: 단어가 특정 토픽에 존재할 확률과 문서에 특정 토 픽이 존재할 확률을 결합확률로 추정하여 토픽을 추출



# **Dynamic Topic Models**

```
keyword_tokenized list = !! 속 각 년도별로 tokenized 결과 저장 (년도별로 총 n개씩 저장됨)
for year in range (2017, 2022)
  for i in range(o, keyworu_num * 2, 2):
   data = pd.read_excel(str(vear) + "_result.xlsx")
   data.drop(['Unnamed: O'], axis=1, inplace=True) # Index 표시 제2
   kevword = data.columns[i]
   keyword_data = data[keyword].tolist()
    for i in range(len(keyword_data)):
     temp = []
     tokenized_sentence = word_tokenize(keyword_data[i])
      for word in pos_tag(tokenized_sentence):
       if ('NN' in word[1]) and (word[0] not in stopwords.words('english')):
           # 단어 앞 뒤에 필요 없는 기호 제거
           text = word[0].strip('\")
           text = text.strip('$')
           text = text.strip('-')
           text = text.strip('#')
           text = text.strip('^')
           text = text.strip('/')
           text = text.strip('%')
           text = text.strip('.')
           text = text.strip('_')
           text = text.strip('~')
           text = text.strip('=')
           text = text.strip('+')
           text = text.strip('*')
           text = text.strip(',')
           if(text == ""):
             continue
           temp.append(text)
      kevword_tokenized_list.append(temp)
```

각 키워드가 연도별로 200개씩 Abstract를 가져왔고 키워드는 총 6개이므로 연도별로는 총 1200개의 abstrac가 존재한다.
Tokenize를 처리하게 되면 총 6000개의 abstract에 대한 tokenize된 집합이존재하게 된다.

문서에 사용할 단어의 개수(N) 설정 = 200

LDA의 토픽 개수(k) 설정 = 50

시계열적 변화를 보기 위한 time slice 지정 = 2017 ~ 2021

# **Dynamic Topic Models**

```
mv_dict = Dictionarv(kevword_tokenized_list)
corpus = [my_dict.doc2bow(text) for text in kevword_tokenized_list]
# 2017 ~ 2021이므로 총 5개 (1200개씩)
time_slice = [data_size, data_size, data_size, data_size, data_size]
# num_topics : tuning해야하는 hyperparameter (토픽 수를 얼마나 설정할 것인지)
corpus-corpus, razwora-my_arct, time_slice=time_slice, num_topics=topic_num)
for i in range(topic_num):
 df = pd.DataFrame()
 for j in range(5):
   li = Idaseq.print_topic_times(i, top_terms=len(my_dict))[j]
   li.sort() # Sorting data
   df[j + 2017] = [val[1] for val in li]
   if(i == 0):
     df.index = [val[0] for val in li]
 df.to_excel("topic" + str(i + 1) + "_dtm.xlsx")
```

DTM 모델인 genism.models의 ldaseqmodel에 넣어, 설정한 토픽 개수만큼의 2017년부터 2021년까지의 시간의 변화가 출력

# **Training Model**

```
for index in range(topic_num):
    dtm_result = pd.read_excel("topic" + str(index+1) + "_dtm.xlsx") # 각 토괵별로 액세 파의 불권음
    # 확습파트 train. label 생성
    for i in range(2017, 2020):
        train_input = np.append(train_input, np.reshape((dtm_result[i] * 1500).to_numpy(), (1, corpus_num)), axis = 0)
   train_label = np.append(train_label, np.reshape((dtm_result[2020] * 1500).to_numpy(), (1, corpus_num)), axis = 0)
    # 컴퓨파트 train, label 세설
    for j in range(2018, 2021):
        test_input = np.append(test_input, np.reshape((dtm_result[i] * 1500).to_numpy(), (1, corpus_num)), axis = 0)
   test_label = np.append(test_label, np.reshape((dtm_result[2021] * 1500).to_numpy(), (1, corpus_num)), axis = 0)
    # 예측파트 input 생성
    for j in range(2019, 2022):
      predict_input = np.append(predict_input, np.reshape((dtm_result[i] * 1500).to_numpv(), (1, corpus_num)), axis = 0)
# topic 단위로 契음
train_input = np.reshape(train_input, (topic_num, 3, corpus_num))
train_label = np.reshape(train_label, (topic_num, corpus_num))
test_input = np.reshape(test_input, (topic_num, 3, corpus_num))
test_label = np.reshape(test_label, (topic_num, corpus_num))
predict_input = np.reshape(predict_input, (topic_num, 3, corpus_num))
# Pytorch tensor로 選割
train_input = Variable(torch.Tensor(train_input)).to(device)
train_label = Variable(torch.Tensor(train_label)).to(device)
test_input = Variable(torch.Tensor(test_input)).to(device)
test_label = Variable(torch.Tensor(test_label)).to(device)
predict_input = Variable(torch.Tensor(predict_input)).to(device)
```

#### <Train\_input>

torch.Size([50, 3, 22685])

<Test\_input>

torch.Size([50, 3, 22685])

<Train\_label>

torch.Size([50, 22685])

<Test\_label>

torch.Size([50, 22685])

<Predict\_input>

torch.Size([50, 3, 22685])

# **Training Model - LSTM**

```
seq_length = 3 #3년치가 LSTM으로 들어가는 살황이므로
hidden_dim = 3 #number of features in hidden state
num_layers = 2 #number of stacked istm layers
num_epochs = 1500 #1500 epochs
learning_rate = 0.002 #0.002 ir
decay = 0.02
input_dim = corpus_num #number of features
output_dim = corpus_num
```

단어 사전에 속한 단어의 개수

Dropout = **0.2** 

Batch\_normalization 1 layer


Bdirectionality = False (단방향)

Activation function = **LeakyReLU(0.1)** 

Optimizer = **Adam** (amsgrad=True)

The number of LSTM stacked layers = 2

Loss function = **MSE** 



# **Training Model**

```
from scipy import stats
test_label = test_label.cpu()
cor = 0
spearman_top = [] # spearman cor 순서대로 저장
for index in range(50):
  predict = predicted[index]
 answer = test_label[index]
  result = stats.spearmanr(predict, answer)
 cor += result[0]
 spearman_top.append((result[0], index))
  print(result)
spearman_top.sort(reverse = True)
print("Spearmanr correlation mean value :", cor / 50)
```


각 토픽의 Spearman Correlation을 구하고 그 값들에 대한 전체 평균으로 모델성능측정

목표치 상관계수가 0.6이면 lstm으로 학습시킨 predicted값들과 라벨 정답값들 사이에 강한 상관관계가 있다고 판단 가능



Spearmanr correlation mean value가 가장 높게 나온 LSTM을 이용하여 2017~2021년의 단어들의 확률값을 input으로 하고 2022년의 키워드를 예측!

### GPT: Generative Pre-Training of a language Model



### **Pre-training model**

이미 존재하는 방대한 양의 unlabeled data를 이용해 모델을 pre-training 시킴으로써 성능을 향상


#### Language model

이전의 말들을 보고 다음에 나타날 말을 예측하여 생성하는 모델

### **Auto-regressive**

GPT는 지금까지 생성된 토큰에 따라 다음 토큰을 순차적으로 생성.

### **GPT**: Model Architecture Design




#### **Decoder-only block**

transformer의 decoder block을 쌓아올린 형태로, encoder-decoder self attention이 제외된 형태

#### Masked multi-head self attention

각 토큰 사이의 관계를 파악하여 self attention을 수행하되 현재 위치보다 앞에 있는 토큰만 입력되도록 제한하는 방식

### GPT 3: enormous training data and model size



https://medium.com/analytics-vidhya/openai-gpt-3-language-models-are-few-shot-learners-82531b3d3122

#### **Model size**


128개의 multi-head attention, 96개의 decoder layer, para meter 개수는 1750억 개에 달하는 방대한 크기의 모델

#### **Training data**

CommonCrawl, WebText2, Wikipedia 등에서 일부 겹치는 데이터를 제거하여 학습에 이용

### **GPT 3:** few-shot learning





### Few-shot learning


주어진 예시와 prompt를 보고 그 다음에 나타날 토큰을 순차적으로 생성하는 방식으로 fine-tuning과 다르게 gradient update가 일어나지 않음

### **GPT 3 API**

### "GPT 3에서 제공하는 openai 패키지를 이용해 few-shot learning 후 키워드를 입력하여 논문 초록 생성하기"

#### **Authentication**

우선 GPT 3 에서 각 유저들에게 제공하는 API key를 입력해야 이용할 수 있다.



### GPT 3 API

### **Few-shot Learning**

openai.Completetion.create()를 이용하여 keyword를 바탕으로 abstract 를 생성한 예시를 제공하고 이를 바탕으로 미래의 논문 초록을 생성

```
class GPT:
    """The main class for a user to interface with the OpenAI API.
    A user can add examples and set parameters of the API request."""
   def add_example(self, ex):
       """Adds an example to the object. Example must be an instance
       of the Example class."""
       assert isinstance(ex, Example), "Please create an Example object."
       self.examples.append(ex.format())
   def submit_request(self, prompt):
       """Calls the OpenAI API with the specified parameters."""
       response = openai.Completion.create(engine=self.get_engine(),
                                          prompt=self.craft_query(prompt),
                                          max_tokens=self.get_max_tokens(),
                                          temperature=self.get_temperature(),
                                          top p=1,
                                          n=1,
                                          stream=False,
                                          stop="\ninput:")
       return response
```

### Results

KEYWORD: 시계열 모델을 통해 예측된 키워드

ABSTRACT: 해당 키워드를 바탕으로 GPT3가 예측한 논문 초록

#### keyword 1

• keyword : classification, representations, order, expression, boundaries

ABSTRACT: The goal of this paper is to investigate the use of representations of order in the context of classification. We present a novel representation, the order graph (OG), which is a directed graph that represents the order of the objects in a given set. We show that the OG can be used to learn a classifier, and that the learned classifier can be used to predict the order of objects in a set. We also show that the OG can be used to learn representations of order that are invariant to the order of the objects in the set. We demonstrate the use of the OG in the context of the classification of protein-protein interactions, and show that it is able to learn representations of order that are invariant to the order of the proteins in the set.

### Results

#### keyword 9

• keyword : number, scene, structure, input, techniques

ABSTRACT: This paper presents a new method for the extraction of numerical values from images. The proposed method is based on the use of the Convolutional Neural Networks (CNN) and the pretraining of the CNN with the ImageNet database. The proposed method is evaluated using the MNIST dataset and the results are compared with the results obtained using the CNN trained with the ImageNet database. The results show that the proposed method is able to extract numerical values from images with a good accuracy.

#### keyword 10

• keyword : number, scene, input, functions, techniques

ABSTRACT: In this paper, we propose a novel method for detecting and counting the number of people in a scene. Our method is based on a convolutional neural network (CNN) and a recurrent neural network (RNN) that is trained to predict the number of people in a scene. The proposed method is able to detect the number of people in a scene even when occlusion occurs. We also propose a method for counting the number of people in a scene using a CNN. The proposed method is able to count the number of people in a scene even when occlusion occurs. Our method is evaluated on three benchmark datasets, namely, Caltech-101, Caltech-256, and MIT-Harvard. Experimental results show that our method outperforms the state-of-the-art methods.

# 감사합니다